

**MBA
USP
ESALQ**

**INTRODUÇÃO AO SOFTWARE
R E INTRODUÇÃO AO
MACHINE LEARNING**

Prof. Dr. Wilson Tarantin Junior

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Introdução ao *Machine Learning*

Machine learning

- Definição
 - Podem ser encontradas muitas definições para o conceito *machine learning*
 - Porém, de forma geral, pode-se entender como a utilização dos dados e de algoritmos (que contêm também métodos estatísticos) para a produção de informações que serão relevantes para a tomada de decisão
 - Por exemplo: criando modelos preditivos ou mesmo classificando dados

Banco de dados

- Definição e composição
 - O banco de dados é o objeto onde estão armazenadas as informações de interesse para a análise ou estudo em questão
 - Em muitos casos, o banco de dados contém uma amostra, que nada mais é do que um subconjunto extraído da população
 - O banco de dados é composto por variáveis e por observações
 - **Variáveis:** características/atributos observados, medidos ou categorizados
 - **Observações:** as unidades que têm suas características e atributos medidos

Banco de dados

- Estrutura para uso
 - Normalmente, o banco de dados é estruturado com as variáveis em colunas e as observações em linhas

	Idade	Altura	Cidade	Profissão	Renda	...
Pessoa 1						
Pessoa 2						
Pessoa 3						
Pessoa 4						
Pessoa 5						
Pessoa 6						
Pessoa 7						
Pessoa 8						
Pessoa 9						
Pessoa 10						
...						

Tipos de variáveis

- As variáveis podem ser divididas em
 - **Métricas:** são as variáveis **quantitativas**, isto é, apresentam características que podem ser mensuradas ou contadas
 - **Não métricas:** são as variáveis **qualitativas**, sendo que indicam características que não podem ser medidas. Tais variáveis contêm categorias, por isto, muitas vezes, são chamadas de variáveis **categóricas**
 - **A identificação do tipo de variável é fundamental para a escolha do método estatístico que será utilizado na análise dos dados**

Variáveis qualitativas

- Características principais
 - As variáveis qualitativas têm sua representação feita por meio de tabelas de distribuição de frequências ou gráficos
 - Também é possível calcular a **moda** de uma variável qualitativa, definida como a categoria que mais repete na distribuição da variável
 - Não é possível calcular outras medidas de resumo como média ou desvio padrão para variáveis qualitativas
 - Exemplos: escalas likert, nacionalidade, cor do veículo, profissão...

Variáveis quantitativas

- Características principais
 - As variáveis quantitativas podem ser representadas por diversas ferramentas, como gráficos, medidas de posição ou localização, dispersão e de forma. A seguir, alguns exemplos:
 - Medidas de posição ou localização: média, mediana, percentis
 - Medidas de dispersão: desvio padrão
 - Medidas de forma: assimetria e curtose
 - Exemplos: idade, renda em Reais, número de habitantes no município, distância em metros, rentabilidade percentual de uma empresa....

Detalhando as variáveis

- Outras características relevantes
 - Variáveis qualitativas: dicotômica ou policotômica; nominal ou ordinal
 - Dicotômica: duas categorias (binária); Policotômica: mais de duas categorias
 - Nominal: não estabelece relação de grandeza/ordem; Ordinal: estabelece uma ordem
 - Variáveis quantitativas: discretas ou contínuas
 - Discretas: possuem conjunto finito e numerável de valores, em geral, são obtidas a partir de dados de contagem (0, 1, 2, 3, 4, 5...)
 - Contínuas: assumem valores pertencentes ao intervalo de números reais

Variáveis e técnicas

- Como identificar a técnica adequada
 - Modelos **não supervisionados** de *machine learning*
 - Também são conhecidos como modelos **exploratórios** ou técnicas de interdependência
 - Estudo da relação entre variáveis, mas sem a intenção de criar modelos confirmatórios
 - Não há inferência dos resultados encontrados para observações fora da amostra
 - Objetivos: redução dos dados, classificação ou agrupamento de observações e variáveis, correlação ou associação entre variáveis

Variáveis e técnicas

- Como identificar a técnica adequada
 - Modelos **supervisionados** de *machine learning*
 - Conhecidos como modelos **confirmatórios** ou técnicas de dependência
 - O objetivo é estimar modelos, equações, com o intuito de **elaborar previsões**
 - Portanto, há **inferência** dos resultados para outras observações fora da amostra


Classificação de algoritmos



SUPERVISIONADOS

NÃO SUPERVISIONADOS

Classificação de algoritmos



Classificação de algoritmos



Referências

Fávero, Luiz Paulo; Belfiore, Patrícia. (2017). Manual de análise de dados: estatística e modelagem multivariada com Excel®, SPSS® e Stata®. Rio de Janeiro: Elsevier

Introdução ao *Software R*

Software R e RStudio

- Apresentação
 - Vamos direto ao RStudio e ao script de aula para conhecermos e aplicarmos os conceitos fundamentais sobre o R!
 - A introdução e apresentação constam no próprio script
 - **Lembrando: primeiramente, sempre vamos descompactar o arquivo (caso esteja compactado) e sempre vamos abrir por meio do arquivo de R Project**
 - **Nos materiais complementares, há um tutorial de instalação dos programas**

Indicações

- Leituras para desenvolvimento no R
 - Hands-On Programming with R (Grolemund, 2014)
 - R for Data Science (Wickham & Grolemund, 2016)
 - Ciência de Dados com R (Guerra, Oliveira, McDonnell & Gonzaga, 2020)