

Disciplina: Unsupervised Machine Learning: Clustering II

Jordana Cristina Borges Arruda Carnicelli

E se no meu banco de dados eu tiver variáveis dummy e também variáveis numéricas, como eu faria para clusterizar?

Resposta: Nesse caso, é o mesmo procedimento.

Ulisses Antonio de Andreis

Quando fui utilizar a função summary para a ANOVA surgiu o seguinte erro: "Error in eval(predvars, data, env) : object 'cluster_K' not found". O que devo fazer? Estou usando um Mac.

Resposta: Olha, parece que você deixou de criar um objeto ou variável, ou seja, de realizar uma etapa anterior. Tente refazer o script. Nesse link também tem uma explicação: Como resolver o erro R em eval(predvars, data, env): objeto não encontrado - The Research Scientist Pod (researchdatapod.com)

Luis Eduardo Orfanelli

No exemplo, o sortimento é a variável de maior amplitude também. Tem relação entre isso e ela ter o maior F value?

Resposta: Necessário especificar melhor a pergunta

Ana Carolina De Oliveira Nascimento

As diferentes variantes do coronavírus foram dispostas em dendogramas através das sequências de DNA, que podem ter 4 possibilidades de resposta (T,C,G e A). Como é feita a análise de clusters nesse caso? Também é uma comparação de variável binária?

Resposta: Acredito que seja o mesmo procedimento. Mas é necessário verificar qual metodologia foi utilizada.

NATANAEL MOURA TEIXEIRA DE JESUS

Como ficaria o controle de variáveis confundidoras nesse caso? Talvez a diferença seja por questões que não estejam mapeadas nas perguntas do banco...

Resposta: Necessário especificar melhor a pergunta

Ederson Rafael Rincel

Olá, estou com o seguinte erro na linha 49, quando utiliza o Scatter 3D: "Error in scatter3D(x = RegionalVarejista\$atendimento, y = RegionalVarejista\$sortimento, : não foi possível encontrar a função "scatter3D""

Resposta: Tente instalar o pacote "car" e "rgl", pois a função não foi encontrada.

Katarina Massako Inoue

Banco de dados não seria um aglomerado de tabelas e na verdade o que o prof ta falando que é um banco de dados é um conjunto de dados?

Resposta: Um banco de dados é um conjunto de dados, sim. Um aglomerado de tabela forma um datalake.

Lauro Lemos Nunes

Quando coloca $h = 10$ na função ele gera a linha bem abaixo de 10, pq não fica exatamente na linha?

Resposta: Padrão do Rstudio.

Adriel Martins Moreira

Qual o critério para selecionar o "complete"? Apenas a visualização do dendrograma?

Resposta: Olha, nesse caso é interessante testar diversos modelos para encontrar aquele que melhor classifica suas observações.

César Kelles Pires De Andrade

Olá Professor Wilson, boa noite! Com relação ao k-means, o que seria preciso modificar o script em R para conseguirmos clusterizar por curva em vez de dados, por exemplo, imagine uma base de consumo de energia elétrica em megawatt, a base de dados seria composta por coluna com nome de agente consumidor e o consumo por mês de jan a dez, cada mês em uma coluna, seria possível rodar o k-means com intuito de clusterizar por curva de consumo (consumo de janeiro a dezembro), isto é, clusterizar por curva em vez de dados?

Resposta: Com certeza é possível. Mas coloque nas observações o que você pretende classificar.

Marco Moreno Nascimento Portilho

No final do 1 exercício dos clusters tivemos os resultados porém não houve uma explicação final relacionando os resultados das colunas clusters com o objetivo de reduzir as observações. Seria possível neste novo exemplo aplicar o resultado ao objetivo final da proposta clustering?

Resposta: Não se trata de redução de observações, mas de mera classificação.

Luiz Fernando Simões Favaro

Na aula passada o professor pulou o slide 12, referente a medida de similaridade de variáveis binárias. Será que ele poderia explicar rapidamente após o intervalo?

Resposta: Nesse caso, é necessário voltar para aula passada ou especificar melhor a pergunta para o e-mail monitordsa@pecege.com.

Stefano Rossetto Paz

É possível explicar brevemente o que está por trás do método K means? Por exemplo como são calculadas as distâncias, etc.

Resposta: Ah, você tem acesso ao livro na biblioteca virtual. As distâncias são calculadas dependendo do método escolhido (single linkage, por exemplo) que utiliza a distância dos vizinhos mais próximos. Além disso, você pode usar a distância euclidiana que utiliza o teorema de pitágoras.

Mario Antonio Stefani

Boa noite! Tenho uma questão referente ao exemplo Hierarquico complete, quando a medida de distancia do terceiro estagio, entre os valores 10,29, 8,42 nas opções disponiveis, foi escolhido o valor 7,19 na tabela euclidiana. Por qual razão foi feita esta escolha?

Resposta: Nesse caso, é necessário especificar melhor a pergunta por email, trazendo o exemplo completo.