

**MBA
USP
ESALQ**

UNSUPERVISED MACHINE LEARNING: Análise Fatorial e PCA

Prof. Dr. Wilson Tarantin Junior

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Contextualização

- Quando aplicar a análise fatorial?
 - Quando as variáveis forem **métricas**: depende das correlações entre variáveis
 - Trata-se do **agrupamento das variáveis** em fatores. Os objetivos podem ser:
 - Obter o comportamento conjunto de variáveis, combinando-as para redução estrutural
 - Análise da validade de construtos pela identificação das variáveis alocadas aos fatores
 - Elaboração de rankings para classificação de desempenho por meio dos fatores
 - Criação de fatores ortogonais entre eles e posterior uso em modelos supervisionados

Contextualização

- Análise fatorial por componentes principais
 - **Componentes principais:** método de determinação dos fatores que se baseia na criação de fatores não correlacionados a partir da combinação linear das variáveis originais
- Análise fatorial PCA: modelo não supervisionado de *machine learning*
 - Portanto, a técnica não tem um caráter preditivo para observações que não estejam presentes na amostra. Se surgirem novas observações, novos fatores atualizados devem ser gerados

Implementação

Matriz de correlações

- Procedimento inicial
 - A PCA fundamenta-se na existência de correlações entre variáveis originais para a criação dos fatores
 - **Coeficiente de correlação de Pearson:** relação linear entre duas variáveis métricas
 - Coeficientes de correlação mais próximos dos valores extremos (-1; +1) propiciam a extração de um único fator → indicam existência de relação entre as variáveis
 - Coeficientes de correlação mais próximos de zero propiciam a extração de diferentes fatores → indicam que a relação entre as variáveis é (praticamente) inexistente

Matriz de correlações

- Procedimento inicial
 - A seguir, tem-se a representação da matriz de correlações para K variáveis e a expressão de cálculo do coeficiente de correlação de Pearson

$$\rho = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1k} \\ \rho_{21} & 1 & \cdots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \cdots & 1 \end{pmatrix}$$

$$\rho_{12} = \frac{\sum_{i=1}^n (X_{1i} - \bar{X}_1) \cdot (X_{2i} - \bar{X}_2)}{\sqrt{\sum_{i=1}^n (X_{1i} - \bar{X}_1)^2} \cdot \sqrt{\sum_{i=1}^n (X_{2i} - \bar{X}_2)^2}}$$

Fonte das equações: Fávero & Belfiore (2017, Capítulo 10)

Adequação global

- A extração de fatores é adequada?
 - Para que a análise fatorial seja adequada, devem existir valores elevados (-1; +1) e estatisticamente significantes na matriz de correlações
 - Para investigar a adequação global da análise fatorial, vamos utilizar o **teste de esfericidade de Bartlett**
 - Os coeficientes de correlação de Pearson são estatisticamente diferentes de zero?

Adequação global

- Teste de esfericidade de Bartlett
 - Compara a matriz de correlações com a matriz identidade de mesma dimensão e espera-se que tais matrizes sejam diferentes para que a análise seja aplicável

$$H_0: \rho = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1k} \\ \rho_{21} & 1 & \cdots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \cdots & 1 \end{pmatrix} = I = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix} \quad H_1: \rho = \begin{pmatrix} 1 & \rho_{12} & \cdots & \rho_{1k} \\ \rho_{21} & 1 & \cdots & \rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{k1} & \rho_{k2} & \cdots & 1 \end{pmatrix} \neq I = \begin{pmatrix} 1 & 0 & \cdots & 0 \\ 0 & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & 1 \end{pmatrix}$$

$$\chi^2_{\text{Bartlett}} = - \left[(n-1) - \left(\frac{2 \cdot k + 5}{6} \right) \right] \cdot \ln |D| \quad \text{com} \quad \frac{k \cdot (k-1)}{2} \text{ graus de liberdade}$$

Fonte das equações: Fávero & Belfiore (2017, Capítulo 10)

Autovalores e autovetores

- Autovalores

- A matriz de correlações de dimensão $K \times K$ possui K autovalores (λ^2) e podem ser obtidos da seguinte forma:

- Solução de $\det(\lambda^2 \cdot I - \rho) = 0$ equivalente a
$$\begin{vmatrix} \lambda^2 - 1 & -\rho_{12} & \cdots & -\rho_{1k} \\ -\rho_{21} & \lambda^2 - 1 & \cdots & -\rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ -\rho_{k1} & -\rho_{k2} & \cdots & \lambda^2 - 1 \end{vmatrix} = 0$$

- Os autovalores indicam o percentual da variância compartilhada pelas variáveis originais para a formação de cada fator

Fonte das equações: Fávero & Belfiore (2017, Capítulo 10)

Autovalores e autovetores

- Autovetores

- Os autovetores da matriz de correlações são obtidos com base em cada um dos autovalores

- $v_{1k}, v_{2k}, \dots, v_{kk}$ são os autovetores para o K-ésimo autovalor (λ^2) em análise

- Solução de
$$\begin{pmatrix} \lambda_k^2 - 1 & -\rho_{12} & \cdots & -\rho_{1k} \\ -\rho_{21} & \lambda_k^2 - 1 & \cdots & -\rho_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ -\rho_{k1} & -\rho_{k2} & \cdots & \lambda_k^2 - 1 \end{pmatrix} \cdot \begin{pmatrix} v_{1k} \\ v_{2k} \\ \vdots \\ v_{kk} \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{pmatrix} \quad \text{ou} \quad \begin{cases} (\lambda_k^2 - 1) \cdot v_{1k} - \rho_{12} \cdot v_{2k} \cdots - \rho_{1k} \cdot v_{kk} = 0 \\ -\rho_{21} \cdot v_{1k} + (\lambda_k^2 - 1) \cdot v_{2k} \cdots - \rho_{2k} \cdot v_{kk} = 0 \\ \vdots \\ -\rho_{k1} \cdot v_{1k} - \rho_{k2} \cdot v_{2k} \cdots + (\lambda_k^2 - 1) \cdot v_{kk} = 0 \end{cases}$$

Fonte das equações: Fávero & Belfiore (2017, Capítulo 10)

Obtenção dos fatores

- Identificação dos *scores* fatoriais
 - Após a análise fatorial ser considerada adequada pelos testes anteriores, será necessário criar os *scores* que geram os fatores propriamente ditos
 - **Scores fatoriais:** são os parâmetros que relacionam o fator com as variáveis originais, representados em um modelo linear
 - Para K variáveis originais, existem, no máximo, K fatores ($F_1, F_2, \dots, F_k$)
 - Os *scores* vêm a partir dos autovalores e autovetores da matriz de correlações

Scores fatoriais

- Definindo os *scores*

- A partir dos autovalores e autovetores, obtém-se os *scores* fatoriais $s_1, s_2, \dots, s_k$
São gerados K grupos de *scores* (é o limite máximo de K fatores possíveis)

$$\mathbf{S}_1 = \begin{pmatrix} s_{11} \\ s_{21} \\ \vdots \\ s_{k1} \end{pmatrix} = \begin{pmatrix} \frac{v_{11}}{\sqrt{\lambda_1^2}} \\ \frac{v_{21}}{\sqrt{\lambda_1^2}} \\ \vdots \\ \frac{v_{k1}}{\sqrt{\lambda_1^2}} \end{pmatrix} \quad \mathbf{S}_2 = \begin{pmatrix} s_{12} \\ s_{22} \\ \vdots \\ s_{k2} \end{pmatrix} = \begin{pmatrix} \frac{v_{12}}{\sqrt{\lambda_2^2}} \\ \frac{v_{22}}{\sqrt{\lambda_2^2}} \\ \vdots \\ \frac{v_{k2}}{\sqrt{\lambda_2^2}} \end{pmatrix} \quad \mathbf{S}_k = \begin{pmatrix} s_{1k} \\ s_{2k} \\ \vdots \\ s_{kk} \end{pmatrix} = \begin{pmatrix} \frac{v_{1k}}{\sqrt{\lambda_k^2}} \\ \frac{v_{2k}}{\sqrt{\lambda_k^2}} \\ \vdots \\ \frac{v_{kk}}{\sqrt{\lambda_k^2}} \end{pmatrix}$$

Fonte das equações: Fávero & Belfiore (2017, Capítulo 10)

Fatores

- Definindo os K fatores
 - O valor do fator F é obtido com as variáveis X transformadas pelo Z-Score (ZX)
 - Tais fatores são ortogonais entre si, ou seja, não são correlacionados

$$\begin{aligned}F_{1i} &= \frac{v_{11}}{\sqrt{\lambda_1^2}} \cdot ZX_{1i} + \frac{v_{21}}{\sqrt{\lambda_1^2}} \cdot ZX_{2i} + \dots + \frac{v_{k1}}{\sqrt{\lambda_1^2}} \cdot ZX_{ki} \\F_{2i} &= \frac{v_{12}}{\sqrt{\lambda_2^2}} \cdot ZX_{1i} + \frac{v_{22}}{\sqrt{\lambda_2^2}} \cdot ZX_{2i} + \dots + \frac{v_{k2}}{\sqrt{\lambda_2^2}} \cdot ZX_{ki} \\F_{ki} &= \frac{v_{1k}}{\sqrt{\lambda_k^2}} \cdot ZX_{1i} + \frac{v_{2k}}{\sqrt{\lambda_k^2}} \cdot ZX_{2i} + \dots + \frac{v_{kk}}{\sqrt{\lambda_k^2}} \cdot ZX_{ki}\end{aligned}$$

Fonte das equações: Fávero & Belfiore (2017, Capítulo 10)

Escolha dos fatores

- Todos os K fatores serão utilizados?
 - Embora seja possível estabelecer a priori quantos fatores são desejados, é de fundamental importância realizar uma análise por meio dos autovalores
 - Lembrando: os autovalores indicam o percentual da variância compartilhada pelas variáveis originais para a formação de cada fator
 - Neste sentido, fatores formados a partir de autovalores menores do que 1 podem não ter representatividade. **O critério de Kaiser (ou critério da raiz latente) indica que sejam considerados apenas fatores correspondentes a autovalores > 1**

Cargas fatoriais

- Análise da composição dos fatores
 - As cargas fatoriais representam as correlações de Pearson entre os fatores e as variáveis originais
 - Pode ser interpretada como a importância de cada variável na constituição daquele fator em particular
 - Quanto maior a carga fatorial, mais aquele fator é influenciado pela variável

Comunalidades

- Composição dos fatores selecionados
 - Ao utilizar o critério da raiz latente, somente os fatores que são derivados de autovalores maiores que 1 serão considerados
 - Portanto, as comunalidades mostram a variância total compartilhada, para cada variável, em todos os fatores extraídos e selecionados com base no critério da raiz latente
 - É possível analisar se houve perda de variância, por variável, após a exclusão de fatores por meio do critério da raiz latente

Criação de rankings

- Soma ponderada e ordenamento
 - Para criar rankings a partir dos fatores obtidos utilizando o critério da soma ponderada e ordenamento, para cada observação da amostra, calcula-se:
 - $\text{Resultado}_i = (F_{1i} * \% \text{ var. comp. } F_1) + (F_{2i} * \% \text{ var. comp. } F_2) + \dots + (F_{ki} * \% \text{ var. comp. } F_k)$
 - Em resumo, multiplica-se o resultado obtido de cada fator por seu percentual de variância compartilhada e depois é realizado o ordenamento do resultado

Referência

Fávero, Luiz Paulo; Belfiore, Patrícia. (2017). Manual de análise de dados: estatística e modelagem multivariada com Excel®, SPSS® e Stata®. Rio de Janeiro: Elsevier