


**MBA
USP
ESALQ**

**SUPERVISED MACHINE LEARNING:
ANÁLISE DE REGRESSÃO SIMPLES E
MÚLTIPLA**

Prof. Dr. Luiz Paulo Fávero

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.



Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98



$$z = \frac{Z_L}{Z_0}$$

$$\Gamma = \frac{V_{\text{reflected}}}{V_{\text{incident}}}$$

$$\frac{a}{b+c} = a \div (b+c) \neq \frac{a}{b} + \frac{a}{c}$$



$$a \times b = w$$

$$b$$

$$\theta$$

$$a$$

$$x = \frac{-b \pm \sqrt{b^2 - 4ac}}{2a}$$

$$b^2 - 4ac$$

$$2a$$

Reflexão

Modelos Supervisionados




“Diferentes pesquisadores, a partir de uma mesma base de dados, podem estimar diferentes modelos e, conseqüentemente, obter diferentes valores previstos do fenômeno em estudo. O objetivo é estimar modelos que, embora simplificações da realidade, apresentem a melhor aderência possível entre os valores reais e os valores previstos”.

Silberzahn, R.; Uhlmann, E. L. Many hands make tight work. **Nature**, v. 526, p. 189-191, Out 2015.


Reflexão

Modelos Supervisionados




Reflexão

Modelos Supervisionados




Reflexão

Modelos Supervisionados





Reflexão

Modelos Supervisionados



Afonso Cesar Leis Brandão 002.499.082-55

Modelos Supervisionados de Machine Learning: Modelos Lineares Generalizados (GLM)





Modelos Lineares Generalizados (GLM)

$$\eta_i = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \dots + \beta_k \cdot X_{ki}$$

Modelos lineares generalizados, características da variável dependente e funções de ligação canônica.

Modelo de Regressão	Característica da Variável Dependente	Distribuição	Função de Ligação Canônica (η)
Linear	Quantitativa	Normal	$\hat{Y}$
Com Transformação de Box-Cox	Quantitativa	Normal Após a Transformação	$\frac{\hat{Y}^\lambda - 1}{\lambda}$
Logística Binária	Qualitativa com 2 Categorias (<i>Dummy</i>)	Bernoulli	$\ln\left(\frac{p}{1-p}\right)$
Logística Multinomial	Qualitativa M ($M > 2$) Categorias	Binomial	$\ln\left(\frac{p_m}{1-p_m}\right)$
Poisson	Quantitativa com Valores Inteiros e Não Negativos (Dados de Contagem)	Poisson	$\ln(\lambda_{poisson})$
Binomial Negativo	Quantitativa com Valores Inteiros e Não Negativos (Dados de Contagem)	Poisson-Gama	$\ln(\lambda_{bneg})$



Fundamentação teórica e conceitos em modelos de regressão

Especificação dos modelos GLM e funções de ligação canônica

Estimação dos parâmetros

Variáveis *dummy*

Procedimento *Stepwise*

Teste de normalidade dos resíduos

Modelos não lineares e transformações de Box-Cox

Diagnósticos de multicolinearidade e heterocedasticidade

Estimações em R

Regressão Linear Simples

Objetivo:

Desenvolver uma equação linear que apresente a relação entre uma variável dependente e uma variável explicativa.

Equação linear de uma reta num plano cartesiano:






$$Y_i = \alpha + \beta \cdot X_i + u_i$$



em que temos um intercepto (α), um coeficiente de inclinação da reta (β), uma variável explicativa X e um termo de erro u .



ARQUIVO
“tempodist.xls”




Análise de Regressão: Coeficiente de Ajuste do Modelo (R^2)

Indica o percentual de variância da variável Y que é devido ao comportamento de variação conjunta da(s) variável(is) explicativa(s) X . Varia de 0 a 1 e, quanto maior o coeficiente, maior o poder preditivo do modelo de regressão, ou seja, maior o poder de explicação do comportamento da variável dependente frente ao comportamento da(s) variável(is) explicativa(s).



Análise de Regressão: Coeficiente de Ajuste do Modelo (R^2)



Comportamento do R^2 para diferentes regressões lineares simples.




Análise de Regressão: Estimação dos Parâmetros

Critérios:

1 – Soma dos erros igual a zero: $\sum_{i=1}^n u_i = 0$


2 – Soma dos erros ao quadrado sendo a mínima possível: $\sum_{i=1}^n u_i^2 = \text{mín}$

Parâmetros α e β podem ser estimados por meio do método dos mínimos quadrados ordinários (MQO), em que a somatória dos quadrados dos termos de erro é minimizada.




Análise de Regressão: Cálculo do R^2


$$R^2 = \frac{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2}{\sum_{i=1}^n (\hat{Y}_i - \bar{Y})^2 + \sum_{i=1}^n (u_i)^2}$$



Apenas Parâmetros e R^2 ?



Apenas Parâmetros e R^2 ?



X Mean: 54.2659224
Y Mean: 47.8313999
X SD : 16.7649829
Y SD : 26.9342120
Corr. : -0.0642526





Modelos de Regressão

no 

Significância Estatística do Modelo

- **Teste F :** Permite analisar se pelo menos um dos β 's é estatisticamente significativo para a explicação do comportamento de Y .
- **Hipóteses:** $H_0: \beta_1 = \beta_2 = \beta_3 = \dots = \beta_k = 0$ H_1 : pelo menos um $\beta \neq 0$

Na rejeição da hipótese nula, pelo menos um dos β 's será estatisticamente diferente de zero para explicar o comportamento de Y -> p-valor abaixo do nível crítico (0,05, usualmente).

Significância Estatística dos Parâmetros do Modelo

- **Teste t:** Permite analisar se cada um dos parâmetros, individualmente, é estatisticamente diferente de zero (no caso de regressão simples, apresenta a mesma significância da estatística F).

- **Hipóteses:** $H_0: \beta = 0$ $H_1: \beta \neq 0$



Avalia-se a significância estatística de cada parâmetro do modelo, para determinado nível de significância (0,05, usualmente).

Comparação entre Modelos

Quando houver o intuito de se compararem os resultados das estimações de dois modelos com quantidades distintas de parâmetros e/ou obtidos a partir de amostras com tamanhos diferentes, faz-se necessário o uso do R^2 ajustado.

$$R^2_{ajust.} = 1 - \frac{n-1}{n-1-k} \cdot (1 - R^2)$$

n : tamanho da amostra;

k : quantidade de variáveis X explicativas.



Regressão Múltipla

Qual a diferença entre um modelo de regressão simples para um modelo de regressão múltipla?

A inclusão de novas variáveis explicativas no modelo!



A forma funcional passa a ser a seguinte:

$$Y_i = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \beta_3 \cdot X_{3i} \dots + \beta_k \cdot X_{ki} + u_i$$

Variáveis Explicativas (X) Qualitativas

- Modelando com variáveis explicativas (X) qualitativas.
- É muito comum observar que diversas variáveis explicativas podem se apresentar de maneira qualitativa (exemplo: rating de crédito, setor de atuação, etc.).
- Dado que tais características não possuem média e nem variância, como incorporá-las ao modelo de regressão?

01000111 1111100 0111101 0111101 1101100 11001010 11101000 1001110 1110111 10100000 1001011 00100001 0001011 01000011 00011100
1100010 10011100 0100010 0101111 1101001 10001 100 1000101 0110101 1000000 0101101 01110000 1011110 10110010 10110101 10011001
11001011 01001001 1100010 0101101 11000101 10001011 01000011 00011100 1100101 01000000 1100100 00011010 100000010 10000010
00100011 00011111 00001000 0101101 01001111 10100101 01111001 1100101 01000000 10011001 111 1001001 10000000 01100110
10111001 01010010 0110001 00000100 00001011 10011100 00011100 1100101 01010010 100011001 01101010 10001101 00000101
00100011 11010010 1000011 00011000 10011100 01111001 1100101 01000001 10100100 01001000 00011011 00100001
01000101 01010001 00100101 11110001 00011011 00011100 01111101 01111101 01111101 11011001
11001010 11101000 10011110 11101111 10100000 01001101 10011100 01001000 01011111 01101111 11011001
10001100 10001101 01110101 10010000 01001101 11111100 01001000 01011101 01111101
10001011 01000011 0100011 00011110 00011100 01001001 01000001 01000001 01000001 01000001 01000001 01000001
10100101 01111001 00111001 1100101 10011001 01001001 11100010 01011101 01111101 01111101 01111101 01111101
1011100 00101000 00010110 00111010 10001010 10000111 00011001 10001101 00011001 00011001 00011001 00011001
01111011 01011010 1001100 10101010 01011010 00011111 00001000 01011011 00011001 00011001 00011001 00011001
00100100 11010110 10101100 01011010 01011010 01011010 01011010 01011010 01011010 01011010 01011010 01011010
10010111 00100001 00010111 01000000 01011010 10011001 10011001 10011001 10011001 10011001 10011001 10011001
01000111 00011111 00001000 01011010 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
10111001 01010010 0100011 00000000 01011010 10011001 10011001 10011001 10011001 10011001 10011001 10011001
01000011 11010010 10000111 00011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
01000111 01000001 01000111 00011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
10011001 11010010 10001101 011110101 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
10011001 11010000 10011110 11011011 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
10011001 01000001 01000111 00011110 00011110 00011110 00011110 00011110 00011110 00011110 00011110 00011110
10101001 01111001 00111001 1100101 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
10011100 00101000 00010110 00111010 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
0111011 01011010 10011001 10011001 10011001 11101101 10011001 10011001 10011001 10011001 10011001 10011001
00100100 11001010 10101100 0101111 00011100 01111001 10011001 10011001 10011001 10011001 10011001 10011001
1001011 00100000 00010111 01000001 00011100 00011100 00011100 00011100 00011100 00011100 00011100 00011100
10100101 01111001 00111001 1100101 10011001 1100101 10011001 1100101 10011001 1100101 10011001 1100101
10011100 00101000 00010110 00111010 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
0111010 10001100 10101010 01011010 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
0111011 01011010 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001 10011001
00100100 10100110 10101100 0101111 00011100 01111001 10011001 10011001 10011001 10011001 10011001 10011001
1001011 00100000 00010111 01000001 00011100 00011100 00011100 00011100 00011100 00011100 00011100 00011100
01100000 10111110 10110010 10110101 10011001 1100101 10011001 1100101 10011001 1100101 10011001 1100101
00000010 11001000 00011010 10010010 10000010 00100001 0001111 00001000 01011011 10100101 01111001 01111001 01101010
00000010 11011011 10010011 10000000 01100110 10111001 01010010 0110001 00000100 00001010 10011100 10000100
10011001 11010100 10001101 01100111 00000010 00100000 11010010 10000011 00011000 10011011 01111011 01011010 11101100
1100001 10100100 01001000 00110111 00100001 01000101 01010001 00110111 1110001 00110111 00100100 11010110 10101100 01011111 00111001

Variáveis Explicativas (X) Qualitativas






Variáveis *dummy*

São variáveis categóricas que representam um atributo por meio de combinação binária (0 para a ausência ou 1 para presença).

E quando tivermos uma variável categórica com mais de uma categoria?

Neste caso, devemos incluir $n - 1$ *dummies*, em que n é a quantidade de categorias existentes na variável original.

Modelos Não Lineares



Resultados da aplicação de quatro diferentes formas funcionais em regressão.

Modelos Não Lineares e Transformações de Box-Cox

An Analysis of Transformations

G. E. P. Box and D. R. Cox

Journal of the Royal Statistical Society.


Series B

(Methodological)

Vol. 26, No. 2 (1964),

pp. 211-252 (42 pages)

Published By: Wiley



<https://www.jstor.org/stable/2984418>

$$Y_{Box-Cox}^* = \frac{Y^\lambda - 1}{\lambda}$$



Qual o valor de λ (λ varia entre $-\infty$ e $+\infty$) que maximiza a aderência da distribuição da nova variável Y^* à normalidade?

Modelos Não Lineares e Transformações de Box-Cox

$Y_i = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Linear ($\lambda = 1$)
$Y_i^2 = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Quadrática ($\lambda = 2$)
$Y_i^3 = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Cúbica ($\lambda = 3$)
$\sqrt{Y_i} = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação de Raiz ($\lambda = 0,5$)
$\frac{1}{Y_i} = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Inversa ($\lambda = -1$)
$\ln(Y_i) = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k$	Especificação Semilogarítmica ($\lambda = 0$) Expansão de Taylor

Modelos Não Lineares e Transformações de Box-Cox

$$\frac{Y_i^\lambda - 1}{\lambda} = \alpha + \beta_1.X_1 + \beta_2.X_2 + \dots + \beta_k.X_k + u_i$$



Diagnóstico de Multicolinearidade

- **Multicolinearidade:** consequência da existência de alta correlação entre duas ou mais variáveis explicativas (preditoras).
- Possibilidade de interpretações erradas pela eventual distorção dos sinais dos parâmetros.
- Erros nas previsões.
- **Como detectar a multicolinearidade?**
 - Sinais inesperados dos coeficientes.
 - Testes t não significantes e teste F significativo.



Diagnóstico de Multicolinearidade

$$Y_i = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i} + \dots + \beta_k \cdot X_{ki} + u_i$$

$$\mathbf{Y} = \mathbf{X} \cdot \mathbf{b} + \mathbf{U}$$

$$\begin{bmatrix} Y_1 \\ Y_2 \\ Y_3 \\ \dots \\ Y_n \end{bmatrix}_{n \times 1} = \begin{bmatrix} 1 & X_{11} & X_{12} & \dots & X_{1k} \\ 1 & X_{21} & X_{22} & \dots & X_{2k} \\ 1 & X_{31} & X_{32} & \dots & X_{3k} \\ \dots & \dots & \dots & \dots & \dots \\ 1 & X_{n1} & X_{n2} & \dots & X_{nk} \end{bmatrix}_{n \times k+1} \cdot \begin{bmatrix} a \\ b_1 \\ b_2 \\ \dots \\ b_k \end{bmatrix}_{k+1 \times 1} + \begin{bmatrix} u_1 \\ u_2 \\ u_3 \\ \dots \\ u_n \end{bmatrix}_{n \times 1}$$

$$\beta = (\mathbf{X}'\mathbf{X})^{-1}(\mathbf{X}'\mathbf{Y})$$



Fontes Geradoras da Multicolinearidade

- 1 - Existência de variáveis que apresentam a mesma tendência durante alguns períodos, em decorrência da seleção de uma amostra que inclua apenas observações referentes a estes períodos.**
- 2 - Utilização de amostras com reduzido número de observações.**
- 3 - Utilização de valores defasados em algumas das variáveis explicativas como “novas” explicativas.**

Consequências da Multicolinearidade

$$Y_i = \alpha + \beta_1 \cdot X_{1i} + \beta_2 \cdot X_{2i}$$

(a) Correlação Perfeita:

$$\mathbf{X} = \begin{bmatrix} 1 & 4 \\ 2 & 8 \end{bmatrix}$$

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 5 & 20 \\ 20 & 80 \end{bmatrix}$$

e, portanto, $\det(\mathbf{X}'\mathbf{X}) = 0$, ou seja, $(\mathbf{X}'\mathbf{X})^{-1}$ não pode ser definida.

Consequências da Multicolinearidade

(b) Correlação Muito Alta, porém Não Perfeita:

$$\mathbf{X} = \begin{bmatrix} 1 & 4 \\ 2 & 7,9 \end{bmatrix}$$

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 5 & 19,8 \\ 19,8 & 78,41 \end{bmatrix}$$

de onde vem que $\det(\mathbf{X}'\mathbf{X}) = 0,01$ e, portanto:

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{bmatrix} 7.841 & -1.980 \\ -1.980 & 500 \end{bmatrix}$$

Consequências da Multicolinearidade

(c) Correlação Baixa:

$$\mathbf{X} = \begin{bmatrix} 1 & 4 \\ 2 & 3 \end{bmatrix}$$

$$\mathbf{X}'\mathbf{X} = \begin{bmatrix} 5 & 10 \\ 10 & 25 \end{bmatrix}$$

de onde vem que $\det(\mathbf{X}'\mathbf{X}) = 25$ e, portanto:

$$(\mathbf{X}'\mathbf{X})^{-1} = \begin{bmatrix} 1 & -0,4 \\ -0,4 & 0,2 \end{bmatrix}$$

Consequências da Multicolinearidade

1 – As significâncias estatísticas dos parâmetros $\beta = (X'X)^{-1}X'Y$ são sensíveis às correlações entre as variáveis explicativas.

2 – Os elementos da diagonal principal da matriz $(X'X)^{-1}$ aparecem no denominador da estatística t . Como a presença da multicolinearidade gera valores muito altos na diagonal da referida matriz, como vimos, ocorre a redução no valor da estatística t , sem alteração no cálculo da estatística F .

Identificação da Multicolinearidade

Regressões auxiliares entre cada uma das explicativas e as demais explicativas:

$$X_2 = \beta_1 + \beta_2.X_3 + \dots + \beta_{k-1}.X_k$$

$$X_3 = \beta_1 + \beta_2.X_2 + \dots + \beta_{k-1}.X_k$$

...

$$X_k = \beta_1 + \beta_2.X_2 + \dots + \beta_{k-1}.X_{k-1}$$



Estatísticas VIF (*Variance Inflation Factor*) e *Tolerance*:

$$Tolerance = 1 - R_p^2$$

$$VIF = 1 / Tolerance$$

em que o R_p^2 é o coeficiente de ajuste da regressão da variável explicativa X_p ($p = 2, 3, \dots, k$) com as demais variáveis explicativas.

Diagnóstico de Heterocedasticidade





Obrigado

Prof. Dr. Luiz Paulo Fávero
LinkedIn