

**MBA
USP
ESALQ**

**ÁRVORES, REDES E ENSEMBLE
MODELS II**

João F. Serrajordia R. de Mello

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Você vai precisar de...



Preparativos

- Abrir o R
- Importar as bibliotecas
- Algo para fazer suas anotações

Recapitulando

rapidamente


Vimos conceitos...




- Machine learning
- IA
- Paradigma machinelânico
- Nomenclaturas

Vimos o conceito de árvores

Vamos classificar este rico senhor:




Falamos sobre overfitting



<http://mlwiki.org/index.php/Overfitting>


Vimos *Cross validation*



A estratégia mais simples é dividir a base em treino e teste.
Desenvolvemos o modelo na base de treino e avaliamos na base de teste.

Avaliamos a árvore

Corte	1-Especificidade	Sensibilidade
0% - 11,1%	100%	100%
11,1% - 11,5%	96%	99%
11,5% - 35,8%	26%	85%
35,8% - 58,9%	12%	72%
58,9% - 66,7%	3%	52%
66,7% - 94,7%	2%	47%
94,7% - 100%	0%	0%



A curva ROC é um gráfico de dispersão de 1-Especificidade no eixo x por Sensibilidade no eixo y, obtidos para cada possível ponto de corte do classificador.

Exercício

E tá lembrado da
atividade??

Bora lá??

Camón, dongle?



AREM2_exercicios_para_casa_da_aula_anterior.R

Agenda



Exercícios

Árvores de regressão

Técnicas de validação cruzada

Bagging – Random Forest

Boosting – Gradient Boosting

Grid Search CV



Árvores de regressão

*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.
Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98


Árvores de regressão

São muito semelhantes a árvores de classificação


O que muda é o critério de impureza

$$SQE = \sum_{i=1}^N (y_i - \hat{y}_i)^2$$

Árvores de regressão



Valores observados vs esperados



Dado: — Esperado — Observado

E a impureza?

$$SSE = \sum_y (y_{observed} - y_{predicted})^2$$



AREM2_script01_Regression_Tree.R

Cross validation



Objetivos

Escolher valores
para os
hiperparâmetros
(*tunning*)


Ter expectativa
melhor da
qualidade (e.g. AUC)
em outras bases

Ideia básica


1. Dividir a base em treino e teste
2. Rodar o modelo com uma configuração de hiperparâmetros na base de treino
3. Avaliar o modelo na base de testes
4. Alterar a configuração e repetir os passos 2 e 3

Será que uma escolha particular da base de treino e teste pode favorecer uma determinada configuração?


Poda da árvore (*Prunning*)



Base de treino: 95%
Base de validação: 40%



Base de treino: 70%
Base de validação: 60%



Base de treino: 65%
Base de validação: 64%

Acurácia

Amostra de treino

Amostra de validação

Estratégias de cross validation

Escolher parâmetros do modelo com uma base de validação ainda pode propiciar overfitting.


Há diversas técnicas de validação cruzada para se evitar esse efeito. No momento vou mencionar uma técnica clássica: dividir a base em Treino, Validação e Teste

+
Amostra de treino

+
Amostra de validação

+
Amostra de teste

K-fold



- Dividimos a base em k sub-amostras
- Para cada sub-amostra:
 - Removemos a sub-amostra como validação
 - Treinamos o modelo com as observações restantes
 - Utilizamos este modelo para classificar a sub-amostra removida
 - Avaliamos a métrica de desempenho do modelo
- Calculamos a média das métricas de desempenho do modelo


K-fold

Tipicamente, fazemos o mesmo para variações do modelo para otimizar hiperparâmetros.



	Acurácia 1	Acurácia 2	Acurácia 3	Acurácia 4	Acurácia Média
Modelo 1	62%	58%	61%	59%	60%
Modelo 2	50%	51%	49%	47%	49%
Modelo 3	72%	68%	71%	75%	72%

Post-prunning com crossvalidation




O pacote rpart faz a poda da árvore realizando um k-fold para otimizar o CP (complexity path), um parâmetro que sumariza a complexidade da árvore. Isso é feito com um *k-fold*.

K-fold no *rpart*

```
14 arvore <- rpart::rpart(Survived ~  
15                          Pclass +  
16                          Sex + Age +  
17                          SibSp +  
18                          Parch +  
19                          Fare +  
20                          Embarked  
21 data=treino,  
22 method='class',  
23 xval=5,  
24 control = rpart.control(cp = 0,  
25                          minsplit = 5,  
26                          maxdepth = 30)
```

O “K” do K-fold



Modelos *Ensemble*:

Onde vivem? O que são?

O que comem?

Predadores naturais

Problemas de preditivos e de classificação




Qual a eficácia de uma vacina?



O cliente vai pagar o empréstimo?



Quanto de petróleo tem no poço?



O cliente vai comprar meu produto?




O que a pessoa está fazendo?



Quão ecológico esse veículo é?

CRISP-DM



Fonte: <https://www.the-modeling-agency.com/crisp-dm.pdf>

Classificação dos algoritmos



Supervisionados

- Regressão
- GLM
- GLMM
- Support vector machines
- Naive Bayes
- K-nearest neighbors
- Redes Neurais
- Decision Trees



Não supervisionados

- K-Means
- Métodos hierárquicos
- Mistura Gaussiana
- DBScan
- Mini-Batch-K-Means

Estamos aqui!

Classificação dos algoritmos



Algoritmos de regressão

- Regressão
- GLM
- GLMM
- Support vector machines
- K-nearest neighbors
- Redes Neurais
- Regression Trees



Algoritmos de classificação

- Regressão logística
- Classification trees
- Redes Neurais
- GLM
- GLMM

Estamos aqui!

Classificação dos algoritmos

Paradigma machine learning

- Árvores de decisão
- Bagging
- Boosting
- K-NN
- Redes Neurais
- Support Vector Machines



Paradigma estatístico

- Regressão
- GLM
- GLMM
- ANOVA



Estamos aqui!



Ensemble

Um ensemble é qualquer mistura de modelos já existentes.
Os principais tipos são:

Bagging

Boosting

Stacking


Bagging é um aggregation

Mas o que é um aggregation oras...


Ensemble - aggregation




Modelo 1



Modelo 2



Modelo 3




Um *aggregation* consiste em uma combinação (em geral uma média simples) das previsões de dois ou mais modelos previamente construídos.

Objetivo: ainda que cada modelo seja um “*weak learner*”, a combinação pode ser um “*Strong learner*” ou um preditor melhor que cada um dos integrantes.


Ensemble – Hard Voting





Modelo 1



Modelo 2



Modelo 3




Classificação mais 'votada'

Ensemble - aggregation




Modelo 1




$$P(\text{blue circle} | \text{person}) = 3\%$$

Modelo 2



$$P(\text{blue circle} | \text{person}) = 7\%$$

Modelo 3



$$P(\text{blue circle} | \text{person}) = 2\%$$

$$P(\text{blue circle} | \text{person}) = 4\%$$

Um método de agregação simples mas poderoso consiste em obter a média de várias previsões.

Ensemble - aggregation

Queremos agregar modelos que sejam:

Úteis

Mirem no mesmo alvo

Diferentes



Árvore 1



Árvore 2



Árvore 3



Classificação mais 'votada'



Queremos preditores diferentes, mas que “apontem” para a mesma variável resposta. Uma ideia seria gerar preditores com alguma ‘perturbação’ aleatória.

Bootstrapping para avaliar a média



E se ao invés de alterar o algoritmo, alterarmos a base usando o mesmo algoritmo?

Bootstrapping para avaliar a média




$$\bar{X}_1$$

Temos um conjunto de dados de tamanho N

Queremos estimar o erro padrão de um parâmetro, por exemplo, a média.

- 1) Retirar uma amostra aleatória de tamanho N da base
- 2) Calcular o parâmetro, armazenar a informação

Bootstrapping para avaliar a média




- 3) Repetimos isso M vezes (digamos... M=10.000 vezes)
- 4) Podemos calcular a média e o erro padrão do estimador




AREM2_script02_bootstraping.R

Bootstrap – aggregation (bagging)



Bagging é um *agregation* do mesmo *algoritmo* em amostras *bootstrap*

Bootstrap – aggregation (bagging)



O bagging com árvores é o famoso *Random Forest*

RANDOM, FORREST, RANDOM!





OMML2_script03_bagging_v2.R

Bagging e Pasting

Bagging

1. Retirar uma amostra aleatória **com reposição** de tamanho N
2. Construir o modelo nessa amostra
3. Repetir 1 e 2 M vezes

Pasting

1. Retirar uma amostra aleatória **SEM reposição** de tamanho $Q < N$
2. Construir o modelo nessa amostra
3. Repetir 1 e 2 M vezes

O *bagging* mais famoso é *Random Forest*, que é feito com árvores, daí o nome.

Características

Bagging

1. Roda em paralelo
2. Também classifica em paralelo
3. Costuma ter bom desempenho sem grandes ajustes

Se ele fosse um carro, eu diria que é um GMC Hummer H3.

Perguntas que eu tinha quando aprendi


Random Forest

1. O *default* é fazer 500 árvores?
2. Demora muito para treinar?
3. E para aplicar a regra? Tenho que aplicar tudo isso de regra? Demora?
4. O algoritmo guarda tudo isso de árvore?

Se ele fosse um carro, eu diria que é um GMC Hummer H3.

Boosting

Correção sequencial de erros




Boosting

- Os métodos de *boosting* são modelos sequenciais que tentam melhorar o erro do modelo anterior

Gradient Boosting

- O *Gradiente Boosting* é uma variação baseada em árvores com alguns hiperparâmetros que controlam o algoritmo








Learning rate

"Estique a corda demais e ela arrebenta, deixe-a muito frouxa, e o instrumento não toca"

Learning rate



O Learning Rate diminui o impacto de cada iteração
costuma demandar mais iterações,
mas ajuda a alcançar melhores resultados

XGBoosting

Nome curto para Extreme Gradient Boosting

É uma implementação do Gradient Boosting

Possui interfaces para R e Python

Ficou famosa por ser usada por vencedores de competições

Criado por Tianqi Chen



O que fazer com meus novos superpoderes?


- Sugestões de prática além da aula:
 - Tentar classificar atividade humana por acelerômetro e giroscópio de celular
<https://archive.ics.uci.edu/ml/datasets/human+activity+recognition+using+smartphones>
 - Identificar doença cardíaca
<https://archive.ics.uci.edu/ml/datasets/Heart+Disease>



Conclusões

- Árvores são só o começo
- Há INFINITAS formas de combinar modelos, essas são as mais famosas
- Esses modelos são difíceis de se interpretar
- O *cross-validation* 'entra no lugar' do *stepwise*
- **PRATIQUE!**





randão 002.499.082-55

Por hoje é só ;)



[linkedin.com/in/joao-serrajordia](https://www.linkedin.com/in/joao-serrajordia)

OBRIGADO!

[linkedin.com/in/joao-serrajordia/](https://www.linkedin.com/in/joao-serrajordia/)