

**MBA  
USP  
ESALQ**

**TEXT MINING,  
SENTIMENT ANALYSIS E  
NLP**

Prof. Dr. Jeronimo Marcondes

\*A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.

**Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98**

# Introdução

O'REILLY®

## Practical Natural Language Processing

A Comprehensive Guide to Building  
Real-World NLP Systems



Sowmya Vajjala,  
Bodhisattwa Majumder,  
Anuj Gupta & Harshit Surana

O'REILLY®

## Text Mining with R

A TIDY APPROACH



Julia Silge & David Robinson

# Plano de ataque

## 1. Conceitos básicos de text mining:


- Técnicas de extração do texto;
- Uso do Tidytext;
- Bag of words
- Conceitos importantes: stop words, stemming, etc
- N gramas
- Modelo em tópicos

## 2. TF-IDF e Análise de sentimentos

# Introdução


- Do que estamos falando?
- O que é PLN?
- Por que PLN? Diferença com relação à Linguagem de Computação
- Qual a ideia do funcionamento?

# Fontes para PLN



Fonte: <https://medium.com/swlh/nlp-text-preprocessing-techniques-ea34d3f84de4>

# Introdução



# Introdução

- Dificuldades com NLP:
  1. Sarcasmo
  2. Conhecimento de domínio comum
  3. Ambiguidade


# Introdução

- Abordagens:

1. Heurística

2. Machine Learning e Deep Learning

# Introdução




# Origem

- Alan Turing
- Como identificar uma máquina?
- Até os anos 80 – várias regras
- Início do Machine Learning

# Usos


- Mecanismos de busca na internet
- Chatbots
- Assistentes virtuais
- Análise de texto – exemplo de artigo
- Spam filter

# PLN Pipeline



# Text Mining

- O que é text mining?



Fonte: <https://www.javatpoint.com/text-data-mining>

# Tidytex e Tidydata


- Hadley Wickham:
  1. Cada variável é uma coluna
  2. Cada observação é uma linha
  3. Cada unidade observacional é a tabela
- Um token por linha!

# Token

TOKEN = Para mineração de texto organizada, o token armazenado em cada linha geralmente é uma única palavra, mas também pode ser um n-grama, frase ou parágrafo.

Menor unidade que importa do texto!

# Tokenização



Fonte: <https://aiplusinfo.com/>

# Token

- “Eu serei um cientista de dados”

|   |           |
|---|-----------|
| 1 | Eu        |
| 2 | serei     |
| 3 | um        |
| 4 | cientista |
| 5 | de        |
| 6 | dados     |

- O R tem funções muito boas para esse processo no pacote tidytext

# Unnest Token

```
text <- c("Because I could not stop for Death -",  
         "He kindly stopped for me -",  
         "The Carriage held but just Ourselves -",  
         "and Immortality")
```

```
text_df <- tibble(line = 1:4, text = text)
```


```
text_df %>% unnest_tokens(word, text)
```

```
text_df %>%  
  unnest_tokens(word, text)  
#> # A tibble: 20 × 2  
#>   line word  
#>   <int> <chr>  
#> 1     1 because  
#> 2     1 i  
#> 3     1 could  
#> 4     1 not  
#> 5     1 stop  
#> 6     1 for  
#> 7     1 death  
#> 8     2 he  
#> 9     2 kindly  
#> 10    2 stopped  
#> # ... with 10 more rows
```

# Unnest Token

- Perceba como a função é útil:
  1. Transforma todas as letras em minúscula;
  2. Tira pontuação;
- Outros pacotes – tem que fazer manualmente.

# Unnest Token



# Bag of Words

- Muito interessante para compreender o texto
- Verifica a frequência dos termos e conta os mesmos ou variável binária que indica presença ou não
- Não é a abordagem em questão – podemos chegar em algo semelhante com dplyr

Bag-of-words (BoW) é um modelo de linguagem estatística usado para analisar texto e documentos com base na contagem de palavras. O modelo não leva em conta a ordem das palavras em um documento.

# Bag of Words

|                    | the | red | dog | cat | eats | food |
|--------------------|-----|-----|-----|-----|------|------|
| 1. the red dog →   | 1   | 1   | 1   | 0   | 0    | 0    |
| 2. cat eats dog →  | 0   | 0   | 1   | 1   | 1    | 0    |
| 3. dog eats food → | 0   | 0   | 1   | 0   | 1    | 1    |
| 4. red cat eats →  | 0   | 1   | 0   | 1   | 1    | 0    |

<https://www.medium.com/>

# Bag of Words

- Essa contagem é muito útil para diversos problemas:
  1. Verificar termos mais comuns;
  2. Verificar termos menos comuns;
  3. Verificar similaridade entre termos e sua quantidade no texto.
- Bag – desconsidera qualquer ordem
- Próxima aula iremos mostrar o TF-IDF

# Data Cleaning

- Muitas palavras devem ser retiradas do texto a depender do que se está extraíndo (data cleaning):
  1. Números;
  2. Emoji;
  3. Caracteres especiais
  4. Espaço em branco
  5. etc

# Stop Words

- Todas as palavras carregam sentido? Algumas carregam pouco ou nenhum: stop words
- <https://gist.github.com/alopes/5358189>
- De, para, que, etc

# Stop Words

- Grande quantidade de listas disponíveis: usar listas pré prontas

```
library(stopwords)
length(stopwords(source = "smart"))
length(stopwords(source = "snowball"))
length(stopwords(source = "stopwords-iso"))
```

# Stop Words

- Aceitável: lista pronta com ajustes
- Toda stop word tem de ser retirada?
- Anti join

```
Data_frame %>% anti_join(get_stopwords(source = "snowball"))
```

# Stemming

- Stemming é o processo de reduzir palavras flexionadas (ou às vezes derivadas) ao seu tronco (stem), base ou raiz, geralmente uma forma da palavra escrita.

|           |        |
|-----------|--------|
| amigos    | amig   |
| amigas    | amig   |
| amizade   | amizad |
| carreira  | carr   |
| carreiras | carr   |

Fonte: <https://www.alura.com.br>

# Stemming

- Diferença com lematização



<https://www.computersciencemaster.com.br/como-reduzir-uma-palavra-ao-seu-radical-em-python-stemming/>

# Stemming

- Diferentes abordagens
- Devemos fazer stemização?

# Token n-gram

- O que é bigrama e n-grama?

|                 |             |             |             |              |         |      |
|-----------------|-------------|-------------|-------------|--------------|---------|------|
| <b>Uni-Gram</b> | This        | Is          | Big         | Data         | AI      | Book |
| <b>Bi-Gram</b>  | This is     | Is Big      | Big Data    | Data AI      | AI Book |      |
| <b>Tri-Gram</b> | This is Big | Is Big Data | Big Data AI | Data AI Book |         |      |

<https://devopedia.org/n-gram-model>



# Correlação

- Há como medir se duas palavras tendem a ocorrer simultaneamente em um documento?
- Tidytext é muito útil para isso
- Correlação de pares – *pairwise correlation*
- Valor de *phi* – correlação de Pearson

# Token n-gram – Correlação

|            | Has word Y | No word Y | Total    |
|------------|------------|-----------|----------|
| Has word X | $n_{11}$   | $n_{10}$  | $n_{1.}$ |
| No word X  | $n_{01}$   | $n_{00}$  | $n_{0.}$ |
| Total      | $n_{.1}$   | $n_{.0}$  | $n$      |

$$\phi = \frac{n_{11}n_{00} - n_{10}n_{01}}{\sqrt{n_{1.}n_{0.}n_{.0}n_{.1}}}$$

<https://www.spss-tutorials.com/pearson-correlation-coefficient/>

# Topic Modelling

- Modelo não supervisionado que permite aproximar partes de documentos por tópicos semelhantes.
- Utilidade prática
- Método LDA

# Final

- Parte prática
- Próxima aula

**OBRIGADO!**

<https://www.linkedin.com/in/jeronymo-marcondes-585a26186>