

**MBA
USP
ESALQ**

**TEXT MINING, SENTIMENT
ANALYSIS E NLP**

Prof. Dr. Jeronimo Marcondes




***A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.**

Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98

Plano de ataque

- TF-IDF
- Análise de sentimentos palavra a palavra
- Análise de sentimentos com algoritmo supervisionado

Plano de ataque



TF-IDF

- 3 formas de se representar um conjunto de textos (nessa aula):
 1. Bag of words
 2. Bag of n-grams
 3. TF-IDF

TF-IDF

- Qual a importância de uma palavra em um texto?
- A depender da escolha anterior – resposta diferente
- Alguns exemplos para bag of words: “para”, “com”, “nome”, etc

TF-IDF

- Stop words ou não, algumas palavras são mais comuns – nem sempre a melhor forma
- Bag of words escolhe a palavra mais comum no word count
- Isso faz com que percamos informação relevante

TF-IDF

- Não podemos levar em conta apenas a frequência (tf), mas também o comportamento das palavras ao longo de um conjunto de documentos: “*corpus*”
- Outra abordagem é observar a frequência de documento inversa (idf) de um termo, o que diminui o peso de palavras comumente usadas e aumenta o peso de palavras que não são muito usadas em uma coleção de documentos.

TF-IDF

- Lei de ZIPF:


A lei de Zipf afirma que no conjunto de dados de uma linguagem, a frequência de uma palavra é inversamente proporcional a sua posição na lista global de palavras depois de classificadas por sua frequência de forma descendente.

Fonte: <https://www.wolfram.com/>

TF-IDF

- TF-IDF visa verificar o quanto uma palavra é importante em um documento
- Intuitivamente, a palavra tem que aparecer muito em um determinado documento, mas sua frequência nos demais documentos não pode ser tão grande

TF-IDF



Fonte: Text Mining with R: a tidy approach

Classificação de texto

- Um dos objetivos mais comuns de NLP
- Colocar um texto em uma categoria.
- O desafio da classificação de textos é “aprender” essa categorização a partir de uma coleção de exemplos para cada uma dessas categorias e prever as categorias para novos.

Classificação de texto

- A classificação de texto é uma técnica de aprendizado de máquina que atribui um conjunto de categorias predefinidas ao texto aberto.
- Exemplos:
 1. Detecção de falas abusivas
 2. Spam Filter
 3. Label em tópicos


Análise de Sentimentos

- Uma das principais formas de categorização: Análise de Sentimentos
- Qual o sentimento envolvido em um texto?
- Exemplo: Críticas de um produto em um site.

Análise de Sentimentos

- Abordagens de análise de sentimentos
- Análise de Sentimentos baseada em palavras
- Abordagem baseada em Machine Learning.

Abordagem Heurística



Datasets de Sentimentos

- AFINN, Bing, NRC.
- Baseados em definição de sentimentos por palavras = unigramas.
- Contém as palavras e os respectivos “scores” de cada uma.

Datasets de Sentimentos

- Métodos baseados em dicionário, como os que estamos discutindo, encontram o sentimento total de um pedaço de texto somando as pontuações de sentimento individuais para cada palavra no texto.
- Sentimento de um texto = valor líquido da soma dos sentimentos de cada palavra.

Procedimento

1. Unnest tokens
2. Datasets de Sentimentos
3. Inner Join

Procedimento

```
#> # A tibble: 303 × 2
#>   word      n
#>   <chr>  <int>
#> 1 good    359
#> 2 young   192
#> 3 friend  166
#> 4 hope    143
#> 5 happy   125
#> 6 love    117
#> 7 deal     92
#> 8 found    92
#> 9 present  89
#> 10 kind    82
#> # ... with 293 more rows
```

```
library(tidytext)

get_sentiments("afinn")
```

```
#> # A tibble: 2,477 × 2
#>   word      value
#>   <chr>    <dbl>
#> 1 abandon  -2
#> 2 abandoned -2
#> 3 abandons  -2
#> 4 abducted  -2
#> 5 abduction -2
#> 6 abductions -2
#> 7 abhor     -3
#> 8 abhorred  -3
#> 9 abhorrent -3
#> 10 abhors   -3
#> # ... with 2,467 more rows
```

Limitações

- Falta de contexto
- Ordem não importa
- Dificuldade de generalização – não há “aprendizado”

Pipeline NLP

- Construir modelo de ML
- Diferentes modelos
- Iremos abordar: Naive Bayes e Support Vector Machine

Métodos ML para NLP

- Qual o objetivo?
- O que procuramos fazer?
- Usos

Naive Bayes


- Baseado no teorema de Bayes
- Suponha dois eventos A e B.

- $$P(A|B) = \frac{P(B|A) \times P(A)}{P(B)}$$

Naive Bayes

- Naive Bayes é um modelo probabilístico baseado no Teorema de Bayes que pode ser utilizado para classificar texto com base nos dados de treinamento.
- Ele estima a probabilidade condicional de uma determinada label ser gerada por uma feature: calcula a probabilidade de ocorrência de cada label sozinha e depois avalia como cada feature pode contribuir para determinados valores.

Naive Bayes





Fonte: Natural Language Processing with Python

O mais comum são labels de automobilismo, portanto começa ali.

Aparecem as palavras “dark” (indicador fraco de mistério) e “football” (indicador forte de esportes).

Naive Bayes




<https://www.statlearning.com/>

Support Vector Machine


- Busca encontrar o melhor hiperplano separado entre duas classes
- 3 possibilidades: classificador de margem máxima, classificador de margem flexível e classificador de margem não linear.

Support Vector Machine




Fonte: Ciência de Dados - Morettin

Support Vector Machine




Fonte: Ciência de Dados - Morettin

Support Vector Machine




Fonte: Elements of Statistical Learning



Fonte: <https://researchgate.com/>

Margem Flexível



Fonte: <https://scikit-learn.org/>

Support Vector Machine

- Objetivo: separar as classes = classificar os textos
- Função objetivo:
 1. Maximizar a margem.
 2. Sujeito ao fato de que cada ponto deve ser maior que a margem.
 3. E sujeito a um possível termo de erro nos modelos de margem flexível.

Performance

- Nem sempre a melhor solução de primeira.

Reason 1 Since we extracted all possible features, we ended up in a large, sparse feature vector, where most features are too rare and end up being noise. A sparse feature set also makes training hard.

Reason 2 There are very few examples of relevant articles (~20%) compared to the non-relevant articles (~80%) in the dataset. This class imbalance makes the learning process skewed toward the non-relevant articles category, as there are very few examples of “relevant” articles.


Reason 3 Perhaps we need a better learning algorithm.

Reason 4 Perhaps we need a better pre-processing and feature extraction mechanism.

Reason 5 Perhaps we should look to tuning the classifier’s parameters and hyperparameters.

Discussão

Futuro de NLP e tendências.



OBRIGADO!

[linkedin.com/in/jeronymo-marcondes-585a26186](https://www.linkedin.com/in/jeronymo-marcondes-585a26186)