

**MBA
USP
ESALQ**

INGENIERÍA DE DATOS I

Prof. Dr. Jeronymo Marcondes

***El profesor es responsable de la idoneidad, originalidad y legalidad de los contenidos didácticos presentados.**

Prohibida la reproducción total o parcial, sin autorización. Ley nº 9610/98


Introducción

¿Por qué estudiar
Ingeniería de Datos?

Ingeniería de Datos
x Ciencia de Datos.

¿Qué es Ingeniería
de Datos?

ETL



Requisitos en grandes empresas

Un profesional de ciencia de datos debe:

- Conocer sobre estructuras de bancos de datos.
- Saber cómo funciona un proceso de *ETL*.
- Entender sobre modelado de bancos de datos.
- Entender cómo funciona el uso de datos en producción.
- **Saber *SQL*.**

Nuestro objetivo

Introducción a
la estructura
de datos.

Banco de
datos
relacional.

SQL.

Modelo ERD –
construcción e
interpretación.

El modelo y el
álgebra
relacional.

Datos

- Datos x Información.
- ¿Qué es un banco de datos?

Es una colección de datos, que describe, tipicamente, las actividades y relaciones de una o más organizaciones.

Ejemplo: MBA USP.

SGBD

Sistema Gestor de Banco de Datos:

Software diseñado para auxiliar en el mantenimiento, organización y recolección de los datos existentes en un banco de datos.

Ejemplo: *MySQL*.


Estructuras de Datos

Los datos que podemos utilizar se dividen en:


- Datos Estructurados.
- Datos Semiestructurados.
- Datos no estructurados.

Structured, Unstructured and Semi-Structured


Structured Data



Semi-Structured Data



Unstructured Data



Fuente: <https://www.astera.com/pt/tipo/blog/dados-semiestruturados-e-n%C3%A3o-estruturados-estruturados/>

Estructurados - son los datos que tienen formatos bien definidos, como los extraídos de planillas o bases de datos relacionales en el formato *SQL*.

Semiestructurados – Similares a los datos estructurados, pero no obedientes en la totalidad cuanto a la forma. En esta línea están los registros de lenguajes basados en *HTML* y *XML*.

No estructurados o *NoSQL* - no poseen un formato específico, son los datos recolectados en su forma original, como un texto, un vídeo, un fragmento de correo electrónico, una sesión de sistema o también una simple foto.

Datos Estructurados

CPF	Nombre	Nota
x	Zé das couves	10
y	Maria das desgraças	2
h	Silvio Santos	5

Datos Semiestructurados

```
[
  {
    "CPF": "x",
    "NOMBRE": "Zé das couves",
    "NOTA": "10",
    "TELEFONO": "no le incumbe"
  },
  {
    "CPF": "y",
    "NOMBRE": "Maria das desgraças",
    "NOTA": "2"
  },
  {
    "CPF": "h",
    "NOMBRE": "Silvio Santos",
    "NOTA": "5",
    "RENTA": "Muy alta"
  }
]
```

Datos No Estructurados



SGBD Relacional

Nuestro enfoque será en SGBD relacional.

Ventajas en el uso de un SGDB:

- Independencia
- Eficiencia.
- Integridad y seguridad.
- Administración simplificada de los datos.
- Control de acceso.

Modelo de datos

- Datos “guardados” en el banco de datos conforme modelo. El SGDB nos permitirá mirar este modelo y hacer consultas conforme la lógica preestablecida.
- La descripción de los datos en términos de modelos es lo que llamamos como **esquema (SCHEMA)**. Según el ejemplo siguiente:

Estudiantes(CPF: *string*, Nombre: *string*, Nota: *Integer*)

Tipos de datos

- Los tipos de datos son clasificados en diferentes categorías y permiten N formatos. Aquí vamos a presentar solamente los más comunes.
- *Integer* o entero. Ejemplo: 1, 2, etc.
- *Float*. Ejemplo: 0.10, 10.25, etc.
- *String*. Ejemplo: “buen día”, “mi nombre es”, etc.
- *Date*. Ejemplo: 2021-01-01.
- Caso del *VARCHAR* y *CHAR*.

Modelo de dados


Estudantes (CPF: *string*, Nombre: *string*, Nota: *Integer*)

- Eso nos dice que se trata de una tabla con tres campos.
- Modelo relacional implica que cada registro es único.
- ¡Restricciones de integridad!

Niveles de Abstracción

Modelo conceptual

- Más alto nivel.
- Más próximo de la realidad del negocio.
- Describe las relaciones entre las entidades presentes en un banco de datos.



Definiciones ERD

- Entidad: Algo que puede ser definido y que puede tener datos almacenados sobre ello – como una persona, un objeto, concepto o evento. Piense en entidades como sustantivos. Ejemplos: un cliente, estudiante, coche o producto.


Definiciones ERD

- Relación: Cómo las entidades actúan unas sobre las otras o están asociadas una con la otra. Piense en relaciones como verbos. Por ejemplo, el estudiante puede inscribirse en un curso. Las dos entidades serían el alumno y el curso, y la relación descrita es el acto de matricularse, conectando así a las dos entidades.

Definiciones ERD

- Atributo: La propiedad o característica de una entidad, a menudo representada por un oval o círculo.

Ejemplo ERD




Niveles de Abstracción

Modelo Lógico

- Como efectivamente los datos estarán dispuestos en tablas en el banco de datos.
- Tiene en cuenta limitaciones del banco y SGBD.
- Define llaves primarias, extranjeras y restricciones de integridad.

Esquema Lógico



Niveles de Abstracción

Modelo Físico

- Implementación propia dicha. Cómo insertar los datos y crear tablas y todo el esquema.
- Más bajo nivel.
- Cómo serán almacenados los datos.
- Métodos de restauración, *backup*.

Query

Dada la existencia de un banco de datos, podemos preguntar:

- ¿Cuántos estudiantes están matriculados en un curso?
- ¿Cuántos cursos están activos?
- ¿Cuál es la edad promedio de los estudiantes?
- ¿Cuál es la edad promedio de los estudiantes de un determinado curso?

Entra *SQL*.

SQL

- *DML – data manipulation language.*
- Universalmente aceita.
- Propria para utilizar álgebra relacional.

Introducción al *SQL*

SQL

- *Structured Query Language.*
- Origen – *IBM.*
- No necesitamos la forma para llegar al resultado – definimos el resultado.
- Lenguaje declarativo.

Aspectos Importantes

DML – manipulação de dados.

DDL – definição de dados.

Acceso remoto a bases de dados.

Gestão de transacciones.

Seguridade.

Forma básica de una *query*

SELECT [*DISTINCT*] lista de selección

FROM lista de origen

WHERE cualificación

Tabla: ***Alumnos***

CPF	Nombre	Nota
x	Zé das couves	10
y	Maria das desgraças	2
h	Silvio Santos	5

Componentes

lista de selección –
columnas que deben
aparecer en el resultado.

lista de origen – cuáles
son las tablas que serán
consultadas.

cualificación –
condiciones que deben ser
impuestas en la consulta.

Ejemplo 1

- ¿Cómo obtener una tabla con CPF y notas?

SELECT **CPF, Nota**

FROM **Alumnos**

Observaciones

- Nombre del campo tiene que ser exacto.
- *SQL es case insensitive.*
- Separe el nombre de las columnas por comas.

Lista- origen y Alias

- Alias es el “sobrenombre”. Muy utilizado en *SQL*.
- Usted puede utilizarlo para facilitar el entendimiento de su *query*.


SELECT A.CPF, A.Nota

FROM Alumnos A

Cualificación

- La cualificación son las famosas cláusulas “*where*”.
- Estas son una combinación de expresiones *booleanas* de condiciones en la forma de expresiones.
- En términos de álgebra, son definiciones de subconjuntos.

Alumnos



Operadores de Comparación

Operador	Significado
=	Igual a
> (Mayor que)	Mayor que
< (Menor que)	Menor que
>= (Mayor o igual a)	Mayor o igual a
<= (Menor o igual a)	Menor que o igual a
<> (Diferente de)	Es diferente de

Ejemplo 2

- ¿Cómo obtener una tabla con CPF y notas mayores que 9?

```
SELECT CPF, Nota  
FROM Alumnos  
WHERE Nota > 9
```

Más de una cláusula

- En este caso, necesitamos definir cómo es la relación entre las cláusulas.
- Supongamos que tenemos 2 condiciones: condición-1 y condición-2.
- *AND* => las dos tienen que ser verdad al mismo tiempo.
- *OR* => una de las dos tiene que ser verdad.

Operador	Significado	Ejemplo
ADN	y	Condición-1 AND condición-2
OR	o	Condición-1 OR condición-2

Ejemplo 3

CPF	NOMBRE	NOTA	EDAD
XX	JOÃO	10	20
YY	PEDRO	7	30

- ¿Cómo obtener todos los registros con nota mayor que 6 Y edad mayor que 25?

SELECT * *

FROM Alumnos

WHERE Nota > 6 *AND* Edad > 25

Ejemplo 4

CPF	NOMBRE	NOTA	EDAD
XX	JOÃO	10	20
YY	PEDRO	7	30



- ¿Cómo obtener todos los registros con la nota mayor que 9 **Ó** edad mayor que 25?

SELECT * *

FROM Alumnos

WHERE Nota > 9 *OR* Edad > 25

Diagrama de Venn



Caso de líneas repetidas

PIS	NOMBRE
xxx	Pedro
xxx	Pedro

- Problema a la hora de la selección cuando aparecen líneas con alguna columna de valores repetidos.
- Uso del *DISTINCT*.

```
SELECT DISTINCT NOMBRE  
FROM Alumnos
```

Agregación

Cómo agregar valores por operaciones.

Operaciones de síntesis de datos:

- Media.
- Mínimo.
- Máximo.
- Etc.

COUNT

- Cuenta la cantidad de registros bajo ciertas condiciones.
- Sigue la siguiente lógica:

SELECT COUNT([Campo Contado]), Campos Agrupados

FROM Tabla

GROUP BY Campos Agrupados

Ejemplo 5

CPF	NOMBRE	ESTADO
XXX	JOÃO	SP
YYY	PEDRO	SP
HHH	MARIANA	AL
JJJ	FLAVIA	RJ

SELECT COUNT(CPF)

FROM Alumnos

4

Ejemplo 6

CPF	NOMBRE	ESTADO
XXX	JOÃO	SP
YYY	PEDRO	SP
HHH	MARIANA	AL
JJJ	FLAVIA	RJ

SELECT COUNT(CPF), ESTADO
FROM Alumnos
GROUP BY ESTADO

2	SP
1	AL
1	RJ

Ejemplo 7

CPF	NOMBRE	ESTADO
XXX	JOÃO	SP
YYY	PEDRO	SP
HHH	MARIANA	AL
JJJ	FLAVIA	RJ

SELECT COUNT(CPF) *AS* conteo, ESTADO
FROM Alumnos
GROUP BY ESTADO
ORDER BY conteo

1	AL
1	RJ
2	SP

SUM

- Suma la cantidad de registros bajo ciertas condiciones.
- Sigue la siguiente lógica:

SELECT SUM([Campo Sumado]), Campos Agrupados
FROM Tabla
GROUP BY Campos Agrupados

Ejemplo 8

CPF	NOMBRE	ESTADO	EDAD
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT SUM(EDAD)
FROM Alumnos

120

Ejemplo 9

CPF	NOMBRE	ESTADO	EDAD
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT SUM(EDAD), ESTADO
FROM Alumnos
GROUP BY ESTADO

50	SP
30	AL
40	RJ

AVERAGE (AVG)

- Saca la media aritmética de los registros bajo ciertas condiciones.
- Sigue la siguiente lógica:

SELECT AVG([Campo]), Campos Agrupados

FROM Tabla

GROUP BY Campos Agrupados

Ejemplo 9

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT AVG(EDAD), ESTADO
FROM Alumnos
GROUP BY ESTADO

25	SP
30	AL
40	RJ

MIN y MAX

- Saca al menor o el mayor valor de los registros bajo ciertas condiciones.
- Sigue la siguiente lógica:

SELECT MIN([Campo]), Campos Agrupados

FROM Tabla

GROUP BY Campos Agrupados

SELECT MAX([Campo]), Campos Agrupados

FROM Tabla

GROUP BY Campos Agrupados

Ejemplo 10

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT MAX(EDAD), ESTADO
FROM Alumnos
GROUP BY ESTADO

30	SP
30	AL
40	RJ

Ejemplo 11

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT MIN(EDAD), ESTADO
FROM Alumnos
GROUP BY ESTADO


20	SP
30	AL
40	RJ

Introducción al *ETL*

*Extract, Transformation
and Load.*

La integración de datos *ETL* es un proceso de tres etapas en que los datos son extraídos de una o más fuentes de datos, convertidos al estado necesario y cargados en un banco de datos o *data warehouse* en la nube.


Estructura de un *ETL*



Frameworks para ETL



Ejemplo Pentaho



Create Table

- Crea una Tabla con ciertos campos.
- Sigue la siguiente lógica:

CREATE TABLE DIRECCION

(
 Id_Estudiente *INTEGER*,
 Direccion *Varchar(50)*
)

Insert

- Inserta ciertos campos.
- Sigue la siguiente lógica:

```
INSERT INTO DIRECCION (Id_Estudiente, Direccion)  
VALUES (2, "CALLE PEIXOTO DA SILVA")
```

¡GRACIAS!

[linkedin.com/in/jeronymo-marcondes-585a26186](https://www.linkedin.com/in/jeronymo-marcondes-585a26186)