

**MBA
USP
ESALQ**

**ENGENHARIA DE
DADOS I**

Prof. Dr. Jeronymo Marcondes

***A responsabilidade pela idoneidade, originalidade e licitude dos conteúdos didáticos apresentados é do professor.**

Proibida a reprodução, total ou parcial, sem autorização. Lei nº 9610/98


Introdução

Por que estudar
Engenharia de Dados?

Engenharia de Dados x
Ciência de Dados.

O que é Engenharia de
Dados?

ETL



Requisitos em grandes empresas

Um profissional de ciência de dados deve:

- Conhecer sobre estruturas de bancos de dados.
- Saber como funciona um processo de ETL.
- Entender sobre modelagem de bancos de dados.
- Compreender como funciona o uso de dados em produção.
- **Saber SQL.**

Nosso objetivo

Introdução à
estrutura de
dados.

Banco de
dados
relacional.

SQL.

Modelo ERD –
construção e
interpretação.

O modelo e a
álgebra
relacional.

Dados

- Dados x Informação.
- O que é um banco de dados?

É uma coleção de dados, que descreve, tipicamente, as atividades e relacionamentos de uma ou mais organizações.

Exemplo: MBA USP.

SGBD

Sistema Gerenciador de Banco de Dados:

Software desenhado para auxiliar na manutenção, organização e coleta dos dados existentes em um banco de dados.

Exemplo: MySQL.


Estruturas de Dados

Os dados que podemos utilizar dividem-se em:


- Dados Estruturados.
- Dados Semiestruturados.
- Dados não estruturados.

Structured, Unstructured and Semi-Structured


Structured Data



Semi-Structured Data



Unstructured Data



Fonte: <https://www.astera.com/pt/tipo/blog/dados-semiestruturados-e-n%C3%A3o-estruturados-estruturados/>

Estruturados - são os dados que detêm formatos bem definidos, como os extraídos de planilhas ou bancos de dados relacionais no formato SQL.

Semiestruturados – Semelhantes aos dados estruturados, mas não obedientes na totalidade quanto à forma. Nesta linha estão os registros de linguagens baseadas em HTML e XML.

Não estruturados ou NoSQL - não possuem um formato específico, são os dados coletados na sua forma original, como um texto, um vídeo, um fragmento de e-mail, um log de sistema ou ainda uma mera foto.

Dados Estruturados

CPF	Nome	Nota
x	Zé das couves	10
y	Maria das desgraças	2
h	Silvio Santos	5

Dados Semiestruturados

```
[
  {
    "CPF": "x",
    "NOME": "Zé das couves",
    "NOTA": "10",
    "TELEFONE" : "não é da sua conta"
  },
  {
    "CPF": "y",
    "NOME": "Maria das desgraças",
    "NOTA": "2"
  },
  {
    "CPF": "h",
    "NOME": "Silvio Santos",
    "NOTA": "5",
    "RENDA": "Muito alta"
  }
]
```

Dados Não Estruturados



SGBD Relacional

Nosso foco será em SGBD relacional.

Vantagens no uso de um SGDB:

- Independência.
- Eficiência.
- Integridade e segurança.
- Administração simplificada dos dados.
- Controle de acesso.

Modelo de dados

- Dados “guardados” no banco de dados conforme modelo. O SGDB nos permitirá olhar este modelo e fazer consultas conforme lógica pré-estabelecida.
- A descrição dos dados em termos de modelos é o que chamamos de **esquema (SCHEMA)**. Conforme exemplo abaixo:

Estudantes(CPF: string, Nome: string, Nota: Integer)

Tipos de dados

- Os tipos de dados são classificados em diferentes categorias e permitem N formatos. Aqui iremos apresentar somente os mais comuns.
- Integer ou inteiro. Exemplo: 1, 2, etc.
- Float. Exemplo: 0.10, 10.25, etc.
- String. Exemplo: “bom dia”, “meu nome é”, etc.
- Date. Exemplo: 2021-01-01.
- Caso do VARCHAR e CHAR.

Modelo de dados


Estudantes(CPF: string, Nome: string, Nota: Integer)

- Isso nos diz que trata-se de uma tabela com três campos.
- Modelo relacional implica que cada registro é único.
- Restrições de integridade!

Níveis de Abstração

Modelo conceitual

- Mais alto nível.
- Mais próximo da realidade do negócio.
- Descreve os relacionamentos entre as entidades presentes em um banco de dados.



Definições ERD

- Entidade: Algo que pode ser definido e que pode ter dados armazenados sobre ele — como uma pessoa, um objeto, conceito ou evento. Pense em entidades como substantivos. Exemplos: um cliente, estudante, carro ou produto.


Definições ERD

- Relacionamento: Como entidades atuam umas sobre as outras ou estão associadas uma com a outra. Pense em relacionamentos como verbos. Por exemplo, o estudante pode se inscrever em um curso. As duas entidades seriam o aluno e o curso, e o relacionamento descrito é o ato de matricular-se, assim conectando as duas entidades.

Definições ERD

- Atributo: A propriedade ou característica de uma entidade, muitas vezes representada por um oval ou círculo.

Exemplo ERD




Níveis de Abstração

Modelo Lógico

- Como efetivamente os dados estarão dispostos em tabelas no banco de dados.
- Leva em conta limitações do banco e SGBD.
- Define chaves primárias, estrangeiras e restrições de integridade.

Esquema Lógico



Níveis de Abstração

Modelo Físico

- Implementação própria dita. Como inserir os dados e criar tabelas e todo o esquema.
- Mais baixo nível.
- Como serão armazenados os dados.
- Métodos de restauração, backup.

Query

Dada a existência de um banco de dados, podemos perguntar:

- Quantos estudantes estão matriculados em um curso?
- Quantos cursos estão ativos?
- Qual a idade média dos estudantes?
- Qual a idade média dos estudantes de um determinado curso?

Entra SQL.

SQL

- DML – data manipulation language.
- Universalmente aceita.
- Própria para usar álgebra relacional.

Introdução ao SQL

Afonso Cesar Lelis Brandão 002.499.082-55

SQL

- Structured Query Language.
- Origem – IBM.
- Não precisamos da forma como chegar no resultado – definimos o resultado.
- Linguagem declarativa.

Aspectos Importantes

DML – manipulação de dados.

DDL – definição de dados.

Acesso remoto a bases de dados.

Gerenciamento de transações.

Segurança.

Forma básica de uma query

SELECT [*DISTINCT*] **lista-seleção**

FROM **lista-origem**

WHERE **qualificação**

Tabela: ***Alunos***

CPF	Nome	Nota
x	Zé das couves	10
y	Maria das desgraças	2
h	Silvio Santos	5

Componentes



lista-seleção – colunas que devem aparecer no resultado.



lista-origem – quais as tabelas que serão consultadas.



Qualificação – condições a serem impostas na consulta.



Exemplo 1

- Como obter uma tabela com CPF e notas?

SELECT CPF, Nota

FROM Alunos

Observações

- Nome do campo tem que ser exato.
- SQL é case insensitive.
- Separe o nome das colunas por vírgulas.

Lista- origem e Alias

- Alias é o “apelido”. Muito usado em SQL.
- Você pode utilizá-lo para facilitar o entendimento de sua query.


SELECT A.CPF, A.Nota

FROM Alunos A

Qualificação

- A qualificação são as famosas cláusulas “where”.
- Essas são uma combinação de expressões booleanas de condições na forma de expressões.
- Em termos de álgebra, são definições de subconjuntos.

Alunos



Operadores de Comparação

Operador	Significado
=	Igual a
> (Maior que)	Maior que
< (Menor que)	Menor que
>= (Maior ou igual a)	Maior ou igual a
<= (Menor ou igual a)	Menor que ou igual a
<> (Diferente de)	É diferente de

Exemplo 2

- Como obter uma tabela com CPF e notas maiores do que 9?

```
SELECT CPF, Nota  
FROM Alunos  
WHERE Nota > 9
```

Mais de uma cláusula

- Neste caso, precisamos definir como é a relação entre as cláusulas.
- Suponha que tenhamos 2 condições: condição-1 e condição-2.
- AND => as duas tem de ser verdade ao mesmo tempo.
- OR => uma das duas tem de ser verdade.

Operador	Significado	Exemplo
AND	e	Condição-1 AND condição-2
OR	ou	Condição-1 OR condição-2

Exemplo 3

CPF	NOME	NOTA	IDADE
XX	JOÃO	10	20
YY	PEDRO	7	30

- Como obter todos os registros com nota maior do que 6 E idade maior do que 25?

SELECT *

FROM Alunos

WHERE Nota > 6 AND Idade > 25

Exemplo 4

CPF	NOME	NOTA	IDADE
XX	JOÃO	10	20
YY	PEDRO	7	30



- Como obter todos os registros com nota maior do que 9 **OU** idade maior do que 25?

SELECT *

FROM Alunos

WHERE Nota > 9 OR Idade > 25

Diagrama de Venn



Caso de linhas repetidas

PIS	NOME
xxx	Pedro
xxx	Pedro

- Problema na hora de seleção quando ocorrem linhas com alguma coluna de valores repetidos.
- Uso do DISTINCT.

```
SELECT DISTINCT NOME  
FROM Alunos
```

Agregação

Como agregar valores por operações.

Operações de sumarização de dados:

- Média.
- Mínimo.
- Máximo.
- Etc.

COUNT

- Conta a quantidade de registros sob determinadas condições.
- Segue a seguinte lógica:

```
SELECT COUNT([Campo Contado]), Campos Agrupados  
FROM Tabela  
GROUP BY Campos Agrupados
```

Exemplo 5

CPF	NOME	ESTADO
XXX	JOÃO	SP
YYY	PEDRO	SP
HHH	MARIANA	AL
JJJ	FLAVIA	RJ

SELECT COUNT(CPF)
FROM Alunos

4

Exemplo 6

CPF	NOME	ESTADO
XXX	JOÃO	SP
YYY	PEDRO	SP
HHH	MARIANA	AL
JJJ	FLAVIA	RJ

SELECT COUNT(CPF), ESTADO
FROM Alunos
GROUP BY ESTADO

2	SP
1	AL
1	RJ

Exemplo 7

CPF	NOME	ESTADO
XXX	JOÃO	SP
YYY	PEDRO	SP
HHH	MARIANA	AL
JJJ	FLAVIA	RJ

SELECT COUNT(CPF) AS contagem, ESTADO
FROM Alunos
GROUP BY ESTADO
ORDER BY contagem

1	AL
1	RJ
2	SP

SUM

- Soma a quantidade de registros sob determinadas condições.
- Segue a seguinte lógica:

```
SELECT SUM([Campo Somado]), Campos Agrupados  
FROM Tabela  
GROUP BY Campos Agrupados
```

Exemplo 8

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT SUM(IDADE)
FROM Alunos

120

Exemplo 9

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT SUM(IDADE), ESTADO
FROM Alunos
GROUP BY ESTADO

50	SP
30	AL
40	RJ

AVERAGE (AVG)

- Tira a média aritmética dos registros sob determinadas condições.
- Segue a seguinte lógica:

```
SELECT AVG([Campo]), Campos Agrupados  
FROM Tabela  
GROUP BY Campos Agrupados
```

Exemplo 9

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT **AVG**(IDADE), ESTADO
FROM Alunos
GROUP BY ESTADO

25	SP
30	AL
40	RJ

MIN e MAX

- Tira o menor ou o maior valor dos registros sob determinadas condições.
- Segue a seguinte lógica:

```
SELECT MIN([Campo]), Campos Agrupados  
FROM Tabela  
GROUP BY Campos Agrupados
```

```
SELECT MAX([Campo]), Campos Agrupados  
FROM Tabela  
GROUP BY Campos Agrupados
```

Exemplo 10

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT MAX(IDADE), ESTADO
FROM Alunos
GROUP BY ESTADO

30	SP
30	AL
40	RJ


Exemplo 11

CPF	NOME	ESTADO	IDADE
XXX	JOÃO	SP	20
YYY	PEDRO	SP	30
HHH	MARIANA	AL	30
JJJ	FLAVIA	RJ	40

SELECT MIN(IDADE), ESTADO
FROM Alunos
GROUP BY ESTADO

20	SP
30	AL
40	RJ


Introdução ao ETL



Extract, Transformation and Load.

A integração de dados ETL é um processo de três etapas em que os dados são extraídos de uma ou mais fontes de dados, convertidos para o estado necessário e carregados em um banco de dados ou data warehouse em nuvem.


Estrutura de um ETL



Frameworks para ETL



Exemplo Pentaho



Create Table

- Cria uma Tabela com determinados campos.
- Segue a seguinte lógica:

```
CREATE TABLE ENDERECO
```

```
(
```

```
    Id_Estudante INTEGER,  
    Endereco Varchar(50)
```

```
)
```

Insert

- Insere determinados campos.
- Segue a seguinte lógica:

```
INSERT INTO ENDERECO (Id_Estudante, Endereco)  
VALUES (2, "RUA PEIXOTO DA SILVA")
```

OBRIGADO!

[linkedin.com/in/jeronymo-marcondes-585a26186](https://www.linkedin.com/in/jeronymo-marcondes-585a26186)